

SISTEMA DE DETECÇÃO DE FALHAS NA FORMAÇÃO DA CASCA EM PROCESSOS DE LINGOTAMENTO CONTÍNUO UTILIZANDO REDES NEURAIS ARTIFICIAIS¹

*Daniel Henrique Dominguete Carvalho*²

*Talles Henrique de Medeiros*³

*Ricardo Fortuna*⁴

RESUMO

O sistema a ser apresentado tem como objetivo prever o comportamento térmico e detectar a presença de bolhas de ar e possíveis vazamentos responsáveis pela má formação da casca em processos de lingotamento contínuo. A solução proporciona uma maior eficiência na produção possibilitando um controle preditivo. A má formação da casca é causada pela presença de bolhas de ar e um resfriamento insuficiente do material liquefeito. Tais situações podem ser visualizadas através de alterações bruscas de temperatura próximas ao molde. Um Sistema Inteligente, baseado em Redes Neurais Artificiais é capaz de prever o comportamento da temperatura a partir de variáveis do processo e reconhecer padrões de comportamento que caracterizam as falhas citadas anteriormente. O sistema é projetado a partir de exemplos de situações anteriores e torna-se uma ferramenta de auxílio para o controle do processo de lingotamento contínuo. O sistema foi construído e testado a partir de um conjunto de amostras de temperatura gerado a partir de informações estatísticas do processo e que pode ser aproximado, com relativa fidelidade, de um sistema real. Os resultados obtidos mostraram-se muito eficientes. O sistema de predição foi capaz de antecipar em até cinco instantes de tempo o valor de temperatura com um erro muito baixo e o detector foi capaz de reconhecer todas as ocorrências de falhas. Deseja-se, como próximo passo, realizar testes com amostras reais de temperatura.

Palavras-chave: Lingotamento Contínuo, Redes Neurais Artificiais.

¹Trabalho a ser apresentado no VII Seminário de Automação de Processos – 6 a 8 de outubro de 2004 – Belo Horizonte – MG - Brasil

²Engenheiro Eletricista, Departamento de Sistemas Inteligentes da Arte & Byte Sistemas Ltda.

³Cientista da Computação, Mestre em Inteligência Computacional, Departamento de Sistemas Inteligentes da Arte & Byte Sistemas Ltda.

⁴Engenheiro Eletricista, Gerente Técnico do departamento de Sistemas Inteligentes da Arte & Byte Sistemas Ltda.

1 - INTRODUÇÃO

O processo de lingotamento contínuo consiste em produzir peças moldadas segundo um formato pré-definido a partir de um processo de solidificação de um material liquefeito. Um fluido constituído de um material liquefeito é despejado em moldes que são submetidos a um processo de resfriamento. O fluido então vai sendo solidificado e tomando a forma imposta pelo molde até que seja obtida uma peça rígida que será submetida a possíveis tratamentos posteriores.

O processo de molde é uma parte importante para a determinação da qualidade do produto final. Nesta etapa, o material liquefeito depositado em um molde deve sofrer um processo de solidificação de modo que assuma uma forma pré-determinada. O processo de solidificação pode ser realizado, por exemplo, por meio de uma refrigeração com água.

À medida que o material fica exposto a esta refrigeração, é criada uma parte mais sólida nas extremidades próximas ao molde denominadas de “casca”. Esta parte sólida vai se expandindo de forma que ao final do processo de resfriamento obtenha-se um material próprio para posteriores tratamentos.

Existem várias características que podem influenciar no processo de molde. Dentre as principais a serem observadas inicialmente pode-se citar:

- Temperatura do aço em processo de solidificação
- Temperatura da água para refrigeração
- Tempo de escoamento do aço ou vazão do mesmo
- Volume de água utilizada para refrigeração
- Temperatura na superfície do molde

Alguns problemas podem ocorrer durante o procedimento de molde, como por exemplo, o *vazamento* e presença de *bolhas de ar*. A Figura 1 ilustra uma ocorrência de vazamento e a Figura 2 apresenta a presença de bolhas de ar durante o processo de solidificação.




Figura 1 – Ocorrência de vazamento na formação da casca




Figura 2 – Ocorrência de bolhas de ar na formação da casca

Uma falha ocorre quando a espessura solidificada é muito pequena e a tira se rompe na saída do processo de solidificação. Esta insuficiência no processo de solidificação pode ser causada pela presença de bolhas de ar e/ou vazamentos. Tal situação representa perda de produção e gastos em reparos.

O sistema proposto a seguir visa impedir a ocorrência de breakouts utilizando técnicas de Inteligência Computacional. Inteligência Computacional que pode ser definida como a área da ciência que estuda a teoria e a aplicação de técnicas inspiradas na Natureza, como as Redes Neurais, Lógica Nebulosa e a Computação Evolucionária [1].

2 – METODOLOGIA

O Sistema Inteligente (SI) apresentado no presente trabalho é capaz de prever o comportamento térmico e detectar antecipadamente possíveis falhas de formação de casca em um processo de lingotamento contínuo. A previsão é possível devido à capacidade de aprendizagem que estes sistemas possuem ao serem treinados com dados históricos do processo em particular. Neste trabalho, são utilizadas as Redes Neurais Artificiais (RNAs) como modelo computacional de aprendizagem baseado em exemplos [2,3].

Deverá ser verificado que o SI é capaz de reconhecer um padrão presente nas amostras dos dados e diante disto ser capaz de prever o comportamento do sistema modelado pela RNA. Com a validação do modelo gerado pela RNA, é possível então promover uma maior eficiência na produção e redução de gastos com manutenção de equipamentos, já que o sistema poderá previamente mostrar o que ocorrerá com o sistema em certas situações. O SI proposto para aplicação em processos de lingotamento é constituído de duas partes: um subsistema inteligente capaz de prever valores de temperatura segundo o comportamento da planta de instantes passados e um outro subsistema capaz de detectar a ocorrência de possíveis falhas causadas pela presença de bolhas de ar e vazamentos na região de casca próxima ao molde.

Ainda não foram tratadas as possíveis correções a serem aplicadas para contornar a ocorrência de bolhas e vazamentos após o momento de sua detecção, sugere-se diminuir a velocidade de escoamento e/ou aumento de vazão de água para resfriamento.

2.1 – Sistema de Previsão de Temperatura

O Sistema de Previsão de Temperatura deverá ser capaz de antecipar, com certa precisão, o comportamento da temperatura medida durante o processo de lingotamento de modo que se possa ganhar tempo para a atuação preventiva para correção do sistema.

O problema principal para o projeto de um sistema de previsão é determinar as principais variáveis que possam representar as situações desejadas. Como proposta inicial pode-se utilizar o valor de temperatura na região superior do processo de solidificação, localizada entre as regiões de Z1 e Z2 da Figura 3.




Figura 3 – Tela de ilustração do processo de lingotamento contínuo

Com os sensores de temperatura enviando informações sobre o comportamento do material em processo de solidificação através do tempo, pôde-se verificar os padrões de comportamento que representam os problemas de vazamento e bolhas de ar.

Em regiões próximas ao molde onde se encontram vazamentos a temperatura apresenta um acréscimo em seu valor, conforme exemplo apresentado na Figura 4. Analogamente, regiões onde existam bolhas de ar, a temperatura apresenta valores inferiores por causa da baixa condutividade térmica do ar, conforme exemplo da Figura 5.



Figura 4




Figura 5

2.2 – Sistema de Detecção de Possíveis Falhas

O Sistema de Detecção de Possíveis Falhas deve ser capaz de identificar, com eficiência, a presença de vazamentos ou bolhas de ar antes da finalização do processo e então alarmar o operador sobre tal situação e/ou tomar as devidas providências como, por exemplo, diminuir a velocidade de escoamento do aço e corrigir os parâmetros do processo de resfriamento (volume e/ou temperatura da água, etc.) através de algum sistema de controle que não será abordado neste texto.

Através de um processo de treinamento das Redes Neurais Artificiais, é possível determinar em tempo real a presença de tais irregularidades por meio do

comportamento da temperatura e tomar as devidas providências de modo a contornar a situação.

2.3 – Geração dos Dados de Treinamento

As Redes Neurais são projetadas a partir de um procedimento de aprendizagem por exemplos [3]. Como não foi possível adquirir amostras de temperatura e outras variáveis do sistema real, foi construída uma série temporal de amostras de temperatura que represente com relativa fidelidade um sistema real de forma a ilustrar a eficiência do sistema.

A caracterização de possíveis falhas é determinada através de alterações abruptas de temperatura. No documento presente foram tratados os casos de vazamentos e presença de bolhas na casca próximo ao molde representados em instantes onde a temperatura sofre uma alteração de seu valor causada pela presença de material ainda não “solidificado” próximo ao molde.

Foram geradas 2000 amostras de temperaturas, dentre elas foram selecionados 26 intervalos onde ocorrem vazamentos e bolhas. Cada vazamento ou bolha foi caracterizado por uma função triangular de comprimento aleatório e um pico de 1% acima ou abaixo da média. Um ruído gaussiano foi somado a toda a série de forma a caracterizar variações de temperatura ao longo do tempo. Foi utilizada uma temperatura média de 1300° C. É importante salientar que quanto maior a duração e o valor máximo destes picos, maior é a facilidade do sistema em se obter as repostas desejadas.

A Figura 6 apresenta o histórico de temperatura utilizada para o teste em questão.

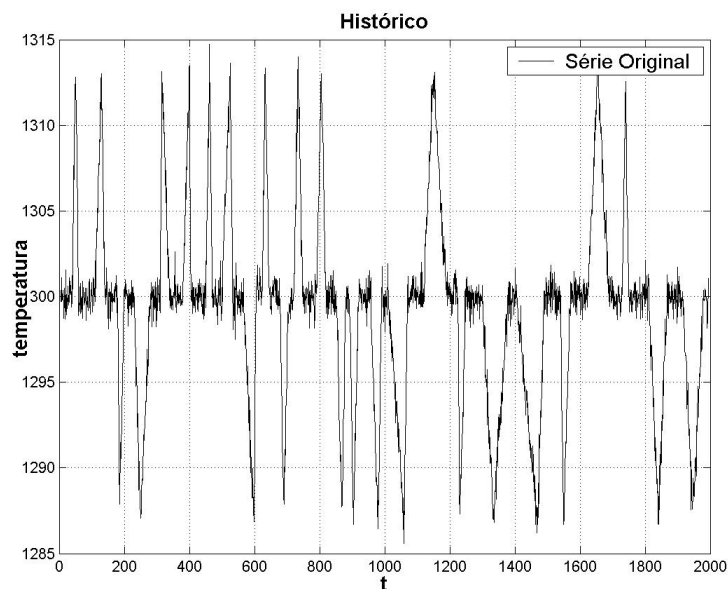


Figura 6

3 - RESULTADOS

Dentre as ferramentas de predição de séries temporais, destacam-se as Redes Neurais Artificiais (RNAs) que são sistemas de computação não lineares, inspirados na estrutura e operação do cérebro humano, tais como: *aprendizado*,

associação, generalização e abstração. Durante este aprendizado, as RNAs são capazes de gerar automaticamente uma correlação entre sinais de entrada e sinais desejados para saída que podem ser tratados como uma base de regras.

Deseja-se que a partir de valores de temperatura de amostras anteriores e/ou outros valores de variáveis do processo (que não foi utilizados no experimento) a Rede Neural Artificial seja capaz de prever valores futuros de temperatura.

Podem ser utilizados diversos métodos de re-amostragem dos dados para treinamento das RNAs, mas neste trabalho utilizou-se o método *Holdout* [4], onde dois subconjuntos de dados: o conjunto de treinamento que é formado por amostras que serão utilizadas para o ajuste da RNA e o conjunto de validação que constitui de amostras que não são utilizadas para o treinamento, mas para uma verificação da resposta da RNA para situações novas.

A Tabela 1 apresenta o resultado obtido para o conjunto de dados em questão:

Tabela 1: Resultados para Predição de Temperatura

	ENTRADAS	PREDITO	NEURÔNIOS	ERRO TREINAMENTO	ERRO VALIDAÇÃO
1	t a t-5	t+1	41	0.814193	0.837546
2	t a t-5	t+5	41	1.684642	1.741381

Analisando os resultados acima é possível assumir que uma rede com 41 neurônios e as entradas formadas pelos cinco últimos valores do histórico pode assumir uma boa topologia para o problema em questão. Sendo possível prever valores de até cinco instantes de tempo adiantado.

Os valores dos erros são calculados pela média dos valores absolutos das diferenças entre o valor desejado e o valor fornecido pela rede.

A Figura 7 apresenta a resposta da RNA para o conjunto de dados de validação do experimento. Neste caso, desejou-se prever o valor da medida de um passo a frente. Estes dados não foram utilizados para o ajuste da rede, demonstrando a capacidade de generalização da RNA e a eficiência do sistema de predição.




Figura 7

Para a Figura 8, a RNA foi treinada para prever o valor de cinco passos à frente, o que obviamente apresenta erros mais elevados que a predição da Figura 7.




Figura 8

As figuras a seguir apresentam um zoom em determinados intervalos para os dois casos em questão.




Figura 9

Como pode ser observado nos resultados experimentais, o sistema de predição de temperatura apresentou um valor baixo de erro médio de predição de 1,80°C para uma amostra a frente e 2,40°C para cinco amostras a frente. Se o tempo de amostragem for de, por exemplo, um minuto, estaríamos detectando um possível breakout em até cinco minutos de vantagem para atuação de correções.




Figura 10

O sistema desenvolvido a partir da base de dados fictícia estaria apto a ser implantado em sistema real, pois apresentou um resultado satisfatório durante a fase de testes pré-liminares.

O resultado da predição poderá ser utilizado no sistema de detecção de possíveis breakouts de forma a realizar uma detecção antecipada de vazamentos e/ou bolhas de ar de forma a possibilitar um controle preditivo do sistema.

Para a detecção de regiões de vazamentos, uma RNA foi treinada para ativar a saída para um determinado valor caso se detecte regiões de pico de temperatura. O conjunto de dados utilizado é o mesmo descrito anteriormente.

Para este caso foram utilizados os valores das últimas cinco leituras de temperatura e a saída de rede é ativada em um valor pré-estabelecido caso esta detecte a ocorrência de um vazamento.

A Figura 11 apresenta um exemplo de saída para a série apresentada no início do documento. Para este caso não foi avaliado o erro de treinamento e validação. Apenas deseja-se que o sistema detecte todos os casos de vazamentos.

Como resultado pode-se notar que o sistema teve uma eficiência de 100% pois foi capaz de detectar todos os picos. E como característica principal, nota-se que a RNA consegue detectar o vazamento muito antes que a temperatura se eleve demais.

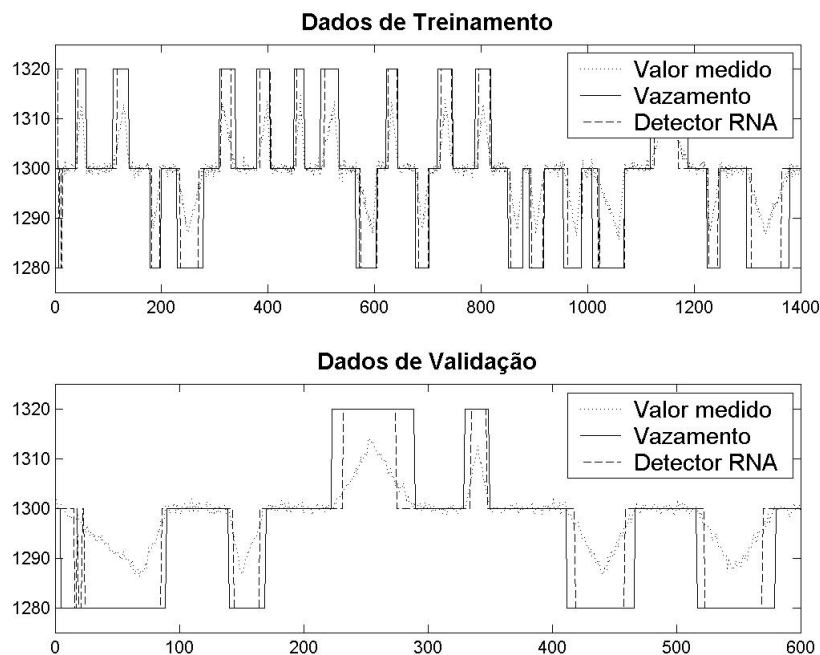


Figura 11

Um sistema composto que utilize a predição para gerar os valores de entrada para o sistema de detecção poderá ser capaz de detectar um vazamento antes mesmo que este chegue a ponto de resfriamento possibilitando ações de controle preditivas.

4 – CONCLUSÃO

Os resultados obtidos com as simulações mostraram a eficiência do uso de técnicas de Inteligência Computacional no procedimento de detecção de falhas da formação de casca em processos de lingotamento contínuo. Como todo modelo de aprendizagem por exemplos, as RNAs são dependentes do conjunto de dados disponíveis para treinamento. Para isso, a precisão da medição tem grande influência na aprendizagem do modelo neural. Os ganhos com a predição realizada poderão promover uma maior eficiência na produção e redução de gastos com manutenção de equipamentos.

5 – REFERÊNCIAS

- [1] CRAENEN, B.C., EIBEN, A.E. **Computational Intelligence**, Faculty of Exact Sciences – Vrije Universiteit Amsterdam, 2000.
- [2] HAYKIN, S. **Neural Networks: A Comprehensive Foundation**. NY : Macmillan, 2001.
- [3] BRAGA, A.P., CARVALHO, A.C.P.L.F e LUDEMIR, T.B. **Redes Neurais Artificiais: Teoria e Prática**, Editora LTC, 2000.
- [4] REZENDE, S.O. **Sistemas Inteligentes: Fundamentos e Aplicações**, Editora Manole, 2002.